

Détection de Pneumonie

sur Radiographies Thoraciques

T-DEV-710 — Rapport de synthèse

Meilleur modèle

CNN (SimpleCNN)

AUC-ROC (test)

0.953

F1-Score (test)

0.928

Précision (test)


90.1 %

Dataset

5 856 images

Classes

NORMALE / PNEUMONIE





Dataset & Distribution des classes

Chest X-Ray Images (Pneumonia) — 5 856 images JPEG en niveaux de gris

Profiling du dataset (pandas)

Split	Classe	Images	Rés. moy.	Rés. min
train	NORMALE	1 341	1 197 × 931	384 × 127
train	PNEUMONIE	3 875	1 056 × 830	384 × 127
val	NORMALE	8	1 063 × 816	422 × 346
val	PNEUMONIE	8	1 053 × 740	461 × 391
test	NORMALE	234	1 048 × 796	384 × 127
test	PNEUMONIE	390	1 090 × 849	384 × 127



Résultats & Comparaison des modèles

Évaluation sur le set de test (données jamais vues à l'entraînement)








Tableau comparatif final

Modèle	Type	Acc. Test	AUC Test	F1 Score
Régression Logistique	ML	0.792	0.862	0.837
KNN	ML	0.773	0.821	0.819
Forêt Aléatoire	ML	0.833	0.887	0.872
SVM (RBF)	ML	0.844	0.903	0.884
CNN (SimpleCNN)	DL	0.901	0.953	0.928


Courbes ROC & Matrices de confusion

Visualisation des performances de classification sur le set de test


Courbes ROC — Tous les modèles



SVM (meilleur ML)



CNN (SimpleCNN)



Méthodologie & Insights

Choix techniques, justifications et conclusions

> Pourquoi la PCA ?

Les images 64×64 produisent 4 096 features. La PCA réduit à 50 composantes capturant >85% de la variance, accélérant les modèles et réduisant le bruit.

> Pourquoi le CNN surpasse les modèles ML ?

Les modèles ML travaillent sur des vecteurs aplatis (perd la structure 2D).
Le CNN apprend des features hiérarchiques (bords → textures → patterns)
via 3 blocs Conv+BN+ReLU+MaxPool, avec invariance aux petites translations.

> Gestion du déséquilibre des classes (74% PNEUMONIE)

- Métrique principale : ROC-AUC (robuste au déséquilibre)
- F1-Score pour pénaliser les faux négatifs
- StratifiedKFold : chaque pli reflète la distribution globale
- Sous-échantillonnage équilibré à 350 images/classe

> Augmentation de données (CNN)

Appliquée à chaque mini-batch : flip horizontal (p=0.5), rotation ±15°, translation affine ±10%, zoom 0.9–1.1, luminosité/contraste ±30%.
Empêche le surapprentissage sur le petit dataset d'entraînement.

> Architecture CNN — 380K paramètres

3 blocs Conv(32→64→128)+BN+ReLU+MaxPool → FC(256)+Dropout(0.5) → FC(1)
Optimizer : Adam (lr=1e-3, weight_decay=1e-4)
Scheduler : StepLR (×0.5 tous les 3 epochs), BCEWithLogitsLoss

> Conclusion & Recommandation

Le CNN SimpleCNN obtient AUC=0.953, F1=0.928 — meilleur de tous les modèles.
Pour un usage clinique : abaisser le seuil à 0.3 pour maximiser le rappel sur la classe PNEUMONIE (éviter les faux négatifs dangereux).
Perspective : transfer learning ResNet18/DenseNet pour dépasser 0.97 AUC.